

Universidad Técnica Particular de Loja

FACULTAD DE INGENIERÍAS Y ARQUITECTURA

Informe: Evaluación de Modelos de Lenguaje

Nombre: Luis Bermeo

Aprendizajes

A través del desarrollo de estas pruebas, se determinó experimentalmente que un Modelo de Lenguaje Grande (LLM) sin un contexto específico (Prompt Base) tiende a tener alucinaciones severas, recurriendo a datos obsoletos o genéricos de su entrenamiento general. La inyección de una base de conocimiento (Prompt Contextualizado) reduce drásticamente las alucinaciones de contenido. No obstante, se observó que no es suficiente para garantizar la confiabilidad del sistema si el usuario altera la semántica de la consulta (preguntar por "semestres" cuando el documento registra "ciclos"). El comportamiento del modelo depende directamente de las instrucciones demostrando que es obligatorio anteponer las reglas de restricción y el rol antes de la pregunta del usuario para evitar el colapso lógico del modelo.

Limitaciones Identificadas

- **Mantenimiento Manual Absoluto:** La base de conocimiento se comporta como un archivo plano estático. Cualquier modificación en la oferta académica, mallas curriculares o sedes activas exige una actualización manual del documento de texto plano, lo cual es inviable en entornos institucionales dinámicos.
- **Falta de Escalabilidad y Saturación de Contexto:** Si el proyecto se expande para cubrir la totalidad de los servicios de la universidad, el volumen de texto superará los límites de la ventana de contexto de los modelos o incrementará exponencialmente el costo de tokens lógicos. Los prompts se volverán demasiado extensos, provocando que modelos más pequeños (como Llama 3.1 8B) ignoren las restricciones por sobrecarga de instrucciones.
- **Inestabilidad del Rol y Falta de Determinismo:** Confiar el comportamiento y las restricciones de seguridad del sistema únicamente a instrucciones en lenguaje natural no es un método 100% confiable. Como se evidenció, ligeros cambios en la redacción pueden causar comportamientos como la inestabilidad del personaje institucional en Llama o rigidez excesiva y pérdida de empatía en Gemini.

Propuestas

Para superar estas limitaciones estructurales, se propone evolucionar el sistema hacia una arquitectura híbrida mediante la implementación de una API de intermediación. Esta interfaz actuará como un puente automatizado entre el LLM y la infraestructura de datos de la organización. En lugar de cargar un archivo de texto estático en el prompt, la API interceptará la consulta del usuario, realizará una búsqueda dinámica en caliente en la base de datos y le entregará al modelo únicamente el registro vigente en tiempo real. Esto garantiza un comportamiento 100% determinista, escalable, libre de mantenimiento manual y con riesgo cero de alucinaciones matemáticas o semánticas.